مرحله دوم پروژه

استاد درس: حسین کارشناس
دستیار درس: پوریا صامتی

مرحله دوم پروژه از دو بخش تشکیل شده است. برای هر بخش دارای یک محیط جداگانه هستیم که هر محیط ویژگی‌های خاص خود را دارد. برای هر محیط باید سیاست تصمیم‌گیری استخراج شود تا بر اساس آن عامل بتواند با محیط تعامل کرده و هدف‌های تعیین شده در هر بخش را کسب کند. بخش اول یک مسأله تصادفی در قالب یک MDP و بخش دوم در رابطه با یک محیط ناشناخته ارائه شده است. توجه کنید برای اجرای این فاز باید کتابخانه pygame را نصب کنید. فایل‌های مورد نیاز را از این لینک دریافت کنید.

۱– فرآیند تصمیم مارکوف

در این بخش هدف این است که مسئله را به صورت یک فرآیند تصمیم‌گیری مارکوف حل کنیم. احتمالاً با بازی معروف Angry Birds آشنایی دارید. شما باید برای پرنده عصبانی سیاستی استخراج کنید که با استفاده از آن بتواند خوک‌ها را نابود کرده و بدون برخورد با ملکه خوک‌ها به نقطه پایان بازی برسد. بازی با کسب امتیاز لازم (در نتیجه نابود کردن تعدادی از خوک‌ها) و رسیدن به تخم‌مرغ‌های موجود در انتهای صفحه بازی به پایان می‌رسد.

۱–۱–معرفی محیط

- یک محیط Grid به ابعاد 8x8 داریم. شروع فعالیت عامل (پرنده عصبانی) در نقطه (0, 0) واقع در موقعیت بالا–چپ است. تخم‌مرغ‌ها در نقطه (7, 7) در موقعیت پایین–راست قرار دارند. در صورت رسیدن عامل به تخم‌مرغ‌ها، عامل **۴۰۰ امتیاز مثبت** دریافت می‌کند.
- پرنده خشمگین دارای کنش‌های تصادفی است. کنش‌های پرنده شامل **بالا، پایین، چپ و راست** می‌باشند. عامل با هر کنشی که در محیط انجام دهد، **یک امتیاز منفی** دریافت خواهد کرد. از آنجا که محیط تصادفی است، کنش در نظر گرفته شده برای عامل با احتمال خاصی انجام می‌شود که به آن کنش اصلی می‌گوییم. در کنار کنش اصلی، عامل با احتمالات دیگری یکی از کنش‌های همسایه را ممکن است به جای کنش‌اصلی انجام دهد. برای مثال اگر کنش در نظر گرفته شده برای عامل "بالا" باشد، عامل به احتمال ۸۰ درصد به سمت بالا حرکت خواهد کرد و به احتمال ۱۰ درصد کنش "چپ" و ۱۰ درصد کنش "راست" را انجام خواهد داد. در جدول زیر کنش اصلی و کنش‌های همسایه آن مشخص شده اند. توجه کنید که احتمال کنش‌ها در بازی می‌تواند متفاوت باشد.

کنش اصلی	کنش همسایه	کنش همسایه
بالا	چپ	راست
پایین	چپ	راست
چپ	بالا	پایین
راست	بالا	پایین

- در بازی ۸ خوک وجود دارد. با هربار اجرای بازی، موقعیت خوک‌ها بطور تصادفی تعیین می‌شود. در نتیجه برخورد با خوک‌ها توسط پرنده، عامل **۲۵۰ امتیاز مثبت** کسب می‌کند.
- دو ملکه در صفحه بازی وجود دارد. با هربار اجرا شدن بازی موقعیت این دو ملکه بصورت تصادفی مشخص می‌شود. در صورت برخورد پرنده با هر ملکه، عامل **۴۰۰ امتیاز منفی** دریافت می‌کند.
- در محیط **۸ سنگ** قرار دارد که عامل نمی‌تواند از آنها عبور کند. موقعیت این سنگ‌ها با هربار اجرای بازی بصورت تصادفی مشخص خواهد شد.

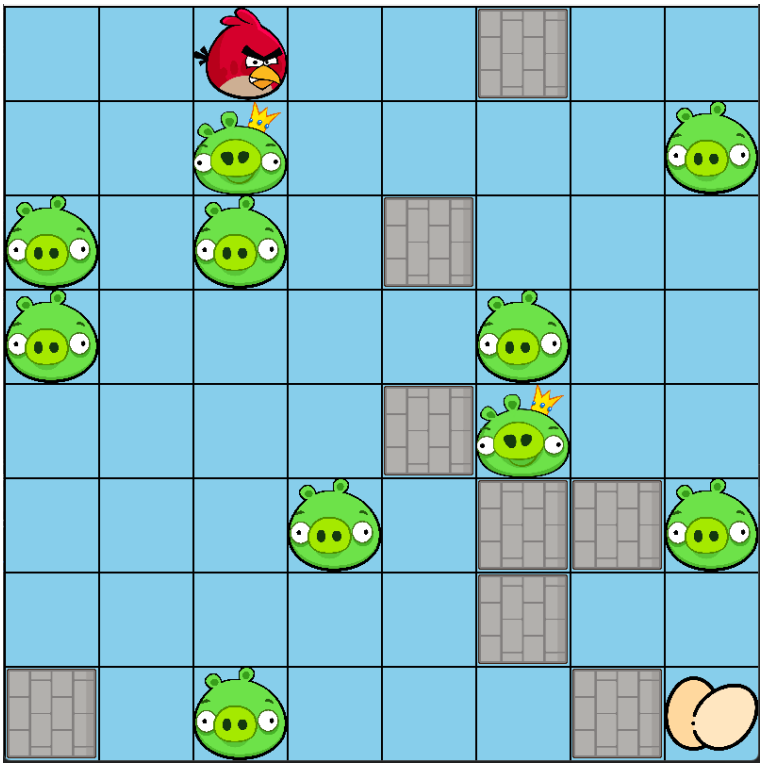

شکل۱-۱محیط Angry Birds برای MDP

۱-۲-مراحل پیاده‌سازی

۱. در ابتدا باید در فایل environment.py تابع reward_function را پیاده‌سازی کنید. توجه کنید که این تابع را باید به شکلی پیاده‌سازی کنید که بر اساس امتیازات معرفی شده در زیربخش قبلی برای نزدیک شدن یا دوری از خوک‌ها، تخم مرغ و دو ملکه پاداش در نظر بگیرد. بدیهی ست که این امتیازات بنا بر نزدیکی خوکها به عامل یا نزدیکی آنها به تخم‌مرغ یا... باید تحت تاثیر قرار بگیرند و باید طوری به آنها امتیاز دهید که عامل شما در نهایت سیاستی را استخراج کند که بتواند امتیاز لازم از خوردن خوکها را بدست آورده و پس از آن به سمت تخم‌مرغ‌ها حرکت کند. شما باید این امتیازات را در قالب یک **مسئله جست‌وجو** با الگوریتم‌هایی که در بخش‌های قبلی درس آموخته اید، محاسبه کنید. توجه کنید که این پاداشی است که برای استخراج سیاست باید از آنها استفاده کنید و لزوماً برابر با امتیازاتی که عامل در حین بازی کسب می‌کند (که در بخش قبل معرفی شدند) نیست.

۲. حال باید الگوریتمی برای استخراج سیاست پیاده‌سازی کنید. برای پیاده‌سازی این الگوریتم از توابعی که برای تعامل با محیط در اختیار شما قرار داده شده استفاده کنید تا به اطلاعات مورد نیاز برای پیاده‌سازی الگوریتم دسترسی داشته باشید. توجه کنید که در این مرحله reward دریافت شده به ازای هر کنش، بر اساس همان تابع پاداشی است که در مرحله ۱ پیاده‌سازی کرده‌اید.

۳. حال پس از اینکه الگوریتم خود را پیاده‌سازی کردید، لازم است تا عامل با استفاده از سیاست استخراجی شما در محیط فعالیت کند. برای انجام اینکار نیز می‌توانید از توابعی که بصورت آماده در اختیار شما قرار داده شده است استفاده کنید.

۱-۳-ارزیابی

در ابتدا باید تابع reward_function شما و الگوریتمی که برای استخراج سیاست پیاده‌سازی کرده‌اید، بررسی شوند. سپس باید اطلاعات زیر را برای اجرای الگوریتم در اختیار ما قرار بدهید:

۱. یک Heat Map که نشان دهنده v_value به ازای هر خانه از محیط بازی می‌باشد. توجه کنید که در کنار سیاست استخراجی، الگوریتم شما باید حتما لیست *V را در خروجی خود داشته باشد. بدیهی است چون محیط دارای ۶۴ خانه است، پس لیست *V نیز باید دارای ۶۴ عضو باشد . شما باید این heat map را از روی لیست *V بسازید. یک Heat Map دو بعدی که مانند صفحه بازی 8x8 باشد.

۲. حال باید در حین اجرای الگوریتم اطلاعاتی را استخراج کنید تا بتوانیم همگرایی الگوریتم شما را بررسی کنیم. بعد از هر iteration که جدول *V بروزرسانی شد، معیار زیر را محاسبه کنید. نام آن Value Difference می‌باشد.

$$Value\ Diffrence\ = \sum_{s \in S} \left| V^{(k+1)}(s) - V^{(k)}(s) \right|$$

توجه کنید که این فرمول بر روی*V قبل از بروزرسانی (اشاره به اندیس k) و پس از بروزرسانی در یک iteration (اشاره به اندیس k+1) را در نظر می‌گیرد. شما در هر iteration از اجرای الگوریتم باید این مقدار را محاسبه کرده و ذخیره کنید و در نهایت نمودار تغییرات آنرا رسم کنید. توجه کنید در صورت همگرایی الگوریتم شما، این معیار باید به مرور کاهش یابد. زمانیکه Value Difference کمتر از یک مقدار مثل ∈ بشود به معنای آن است که می‌توانیم اجرای الگوریتم را متوقف کنیم. . مقدار ∈ یک عدد بسیار کوچک (به عنوان مثال 0.01 یا 0.001) است.

۳. حال در مرحله بعد خروجی الگوریتم شما باید یک سیاست باشد که عامل بتواند با استفاده از آن در محیط فعالیت کند. به این منظور عملکرد عامل در محیط‌های مختلف (با نقشه‌های متفاوت) مورد ارزیابی قرار می‌گیرد. با توجه به تصادفی بودن محیط، برای هر محیط عملکرد عامل در ۵ دور مورد بررسی قرار می‌گیرد. در هر دور عامل با شروع از نقطه ابتدایی بازی باید سیاست بهینه را محاسبه کرده (یا با بکارگیری سیاست بهینه محاسبه شده در دورهای قبلی) و با استفاده از آن به کسب امتیاز در محیط پرداخته و در نهایت به تخم‌مرغ‌ها برسد تا آن دور از بازی به پایان برسد. میانگین امتیاز دریافت شده عامل در ۵ دور، عملکرد او را در این محیط نشان می‌دهد. در این ۵ دور ویژگی‌های محیط تغییری نخواهد کرد و بنابراین همانطور که گفته شد می‌توانید فقط در دور اول سیاست بهینه را استخراج کرده و در سایر دورها از همان سیاست استفاده کنید. این روند برای تعدادی محیط که برای ارزیابی در نظر گرفته شده است تکرار شده و بر اساس برآیند امتیازات بدست آمده مطابق جدول زیر نمره دریافتی شما مشخص می‌شود:

میانگین امتیاز دریافتی	نمره
1300 < mean score	100 %
1150 < mean score < 1300	80 %
900 < mean score < 1150	60 %
900 > mean score	50 %

۲- محیط‌های ناشناخته

در این بخش باید الگوریتمی را پیاده‌سازی کنید تا بتواند در محیط ناشناخته فعالیت کند و یک سیاست برای حل مسئله استخراج کند. نام این محیط Unknown Angry Birds است.

۲-۱-معرفی محیط

- یک محیط Grid به ابعاد 8x8 هستیم. در این محیط باید پرنده زرد که در ابتدای بازی در موقعیت (0, 0) یعنی بالا-چپ قرار دارد به پرنده آبی برسد که در موقعیت (7, 7) یعنی پایین-راست قرار دارد. پرنده زرد دارای چهار کنش **بالا، پایین، چپ و راست** می‌باشد. در صورت رسیدن به پرنده آبی **٤٠٠ امتیاز** کسب خواهید کرد و بازی **خاتمه** می‌یابد. هر کنش پرنده زرد نیز **یک امتیاز منفی** در پی خواهد داشت.
- در این محیط **۸ مانع** قرار دارند که عامل نمی‌تواند از آنها عبور کند. این موانع در ابتدای ایجاد محیط بصورت تصادفی در خانه‌ها قرار می‌گیرند.
- در این محیط **۸ خوک** وجود دارد که در صورت برخورد پرنده زرد با آنها عامل **۲۵۰ امتیاز مثبت** دریافت کرده و آنها را از بین می‌برد. موقعیت قرارگیری این ۸ خوک در خانه‌ها در ابتدای ایجاد محیط بطور تصادفی مشخص می‌شود.
- در این محیط **۲ ملکه‌خوکی** قرار دارند که در صورت برخورد عامل با هر ملکه، **٤٠٠ امتیاز منفی** دریافت می‌کند. موقعیت این ملکه‌ها نیز در ابتدای ایجاد محیط بطور تصادفی تعیین می‌شود.
- در این محیط یک TNT قرار دارد که در صورت برخورد با آن عامل **۲۰۰۰ امتیاز منفی** دریافت کرده و بازی **خاتمه** می‌یابد. موقعیت TNT بطور تصادفی در ابتدای تعیین می‌شود.
- عامل فقط **۱۵۰ کنش** فرصت دارد تا به پرنده آبی برسد. در صورتیکه تعداد کنش‌های عامل بیشتر از این تعداد شود، **۱۰۰۰ امتیاز منفی** دریافت کرده و بازی **خاتمه** می‌یابد.
- مانند بخش قبلی عامل دارای کنش‌های تصادفی است. کنش در نظر گرفته شده برای عامل با احتمال خاصی انجام خواهد شد که به این کنش، کنش اصلی گفته می‌شود. کنش‌اصلی دارای دو کنش همسایه است که آنها نیز احتمال خاصی دارند و ممکن است یکی از آنها به جای کنش اصلی انجام شود. توجه کنید که توزیع احتمالاتی کنش‌ها در یک بازی ثابت ولی در بازی مختلف می‌تواند فرق داشته باشد. کنش اصلی و کنش‌های همسایه آن به شرح زیر هستند:

کنش اصلی	کنش همسایه	کنش همسایه
بالا	چپ	راست
پایین	چپ	راست
چپ	بالا	پایین
راست	بالا	پایین

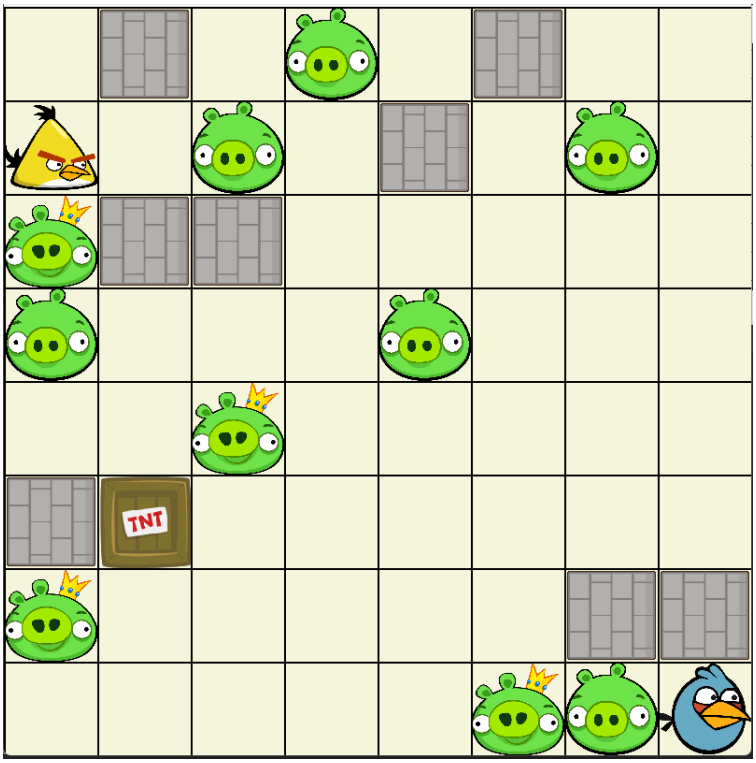

شکل۲-۱ محیط *Unknown Angry Birds*

۲-۲-مراحل پیاده‌سازی

۱. در ابتدا باید با استفاده از الگوریتم‌های موجود در محیط‌های ناشناخته، یک سیاست در محیط استخراج کنید. انتخاب الگوریتم برعهده شما می‌باشد. توصیه می‌شود الگوریتم‌های مختلف را پیاده‌سازی کرده و عملکرد هر کدام را بررسی کنید.

۲. تفاوت مهم این بخش نسبت به بخش قبلی در این است که عامل معمولاً نمی‌تواند تنها با یک دور (episode) از فعالیت در محیط سیاست بهینه را استخراج کند. به همین دلیل لازم عامل دورهای متعددی از فعالیت در محیط را سپری کند و دانش استخراج شده از آنها را با هم ترکیب کند تا یادگیری تحقق پیدا کند. به عنوان مثال اگر دانش استخراج شده از محیط در قالب یک جدول Q باشد، عامل باید در ابتدای هر دور جدول ذخیره شده قبلی را بازیابی کرده، در حین فعالیت در آن دور آن را بروزرسانی کرده و دوباره در پایان دور آن را ذخیره کند، تا در نهایت به یک سیاست خاص همگرا شود.

۳. حال باید در حین اجرای الگوریتم اطلاعاتی را استخراج کنید تا بتوانیم همگرایی الگوریتم شما را بررسی کنیم. بعد از هر episode که جدول Q* بروزرسانی شد، معیار زیر را محاسبه کنید. نام آن Value Difference می‌باشد.

$$Value\ Diffrence\ = \sum_{s\in S}\sum_{a\in A}\left|Q^{(k+1)}(s,a) - Q^{(k)}(s,a)\right|$$

توجه کنید که این فرمول بر روی جدول Q* قبل از بروزرسانی (اشاره به اندیس k) و پس از بروزرسانی در یک episode (اشاره به اندیس k+1) را در نظر می‌گیرد. شما در هر episode از اجرای الگوریتم باید این مقدار را محاسبه کرده و ذخیره کنید و در نهایت نمودار تغییرات آنرا رسم کنید. توجه کنید در صورت همگرایی الگوریتم شما، این معیار باید به مرور کاهش یابد. زمانیکه Value Difference کمتر از یک مقدار مثل ∈ بشود به معنای آن است که می‌توانیم اجرای الگوریتم را متوقف کنیم. . مقدار ∈ یک عدد بسیار کوچک (به عنوان مثال 0.01 یا 0.001) است.

۴. در راستای ارزیابی سیاست استخراج شده نیاز است که روی یک نقشه، کنشی که سیاست برای آن حالت پیشنهاد داده است را نشان دهید. یک نقشه به ابعاد 8x8 بسازید و روی هر حالت کنش پیشنهادی سیاست را نمایش دهید.

۵. پس از همگرایی الگوریتم، با توجه به سیاست استخراج شده در ماتریس *Q عامل باید به فعالیت در محیط بپردازد.

۲-۳-ارزیابی

در ابتدا الگوریتم شما مورد بررسی قرار گرفته و صحت و شیوه پیاده‌سازی آن ارزیابی خواهد شد. سپس همگرایی الگوریتم شما با توجه به نموداری که در بخش ۲-۲ معرفی شد بررسی خواهد شد.
پس از اجرای الگوریتم و بررسی همگرایی آن، عملکرد عامل برای فعالیت در محیط بر اساس سیاست استخراج شده مورد ارزیابی قرار می‌گیرد. مانند بخش قبلی عامل در تعدادی محیط و در هر محیط ۵ دور فعالیت خواهد کرد. هر دور از فعالیت عامل با رسیدن به یکی از شرایط پایان بازی متوقف شود و که میانگین امتیازاتش در همه دورها محاسبه می‌شود. در نهایت نمره شما براساس برآیند امتیازاتی که عامل در محیط‌های مختلف کسب کرده است، مطابق با جدول زیر مشخص خواهد شد.

میانگین امتیاز دریافتی	نمره
mean score > 1100	100 %
mean score > 850	70 %
mean score > 600	50 %
برخورد با TNT (در صورتیکه سیاست استخراج شده عامل را به سمت TNT هدایت کند)	0 %

۲-۴-بخش امتیازی

پیاده‌سازی یک شبکه‌عصبی مبتنی بر Deep QLearning با استفاده از کتابخانه‌های Pytorch یا TensorFlow. ورودی شبکه‌عصبی باید حالتی از محیط باشد و لایه خروجی شبکه‌عصبی باید دارای ۴ خروجی باشد(به تعداد کنش‌ها). عامل برای تصمیم‌گیری در انتخاب کنش در هر حالت باید از این شبکه استفاده کند.

موفق باشید